Nama: Virgie Yunita Salsabil

NIM : 21110022 Kelas : S1-SD02A

#### **RESPONSI**

#### 1. CPMK1- Sub CPMK1.1 ( bobot : 10 )

- · Lakukan crawling data teks dari media sosial/ web dan simpan hasilnya dalam bentuk excel/csv.
- Setiap mahasiswa harus melakukan crawling dengan kata kunci tertentu.
- Kata kunci tidak boleh sama dengan mahasiswa lainnya.

15 from Sastrawi.Stemmer.StemmerFactory import StemmerFactory

```
1 # Instalasi pustaka nltk (Natural Language Toolkit) utk pemrosesan bahasa alami.
 2 !pip install nltk
     Requirement already satisfied: nltk in /usr/local/lib/python3.10/dist-packages (3.8.1)
     Requirement already satisfied: click in /usr/local/lib/python3.10/dist-packages (from nltk) (8.1.7)
     Requirement already satisfied: joblib in /usr/local/lib/python3.10/dist-packages (from nltk) (1.3.2)
     Requirement already satisfied: regex>=2021.8.3 in /usr/local/lib/python3.10/dist-packages (from nltk) (2023.6.3)
     Requirement already satisfied: tqdm in /usr/local/lib/python3.10/dist-packages (from nltk) (4.66.1)
 1 # Instalasi pustaka sastrawi utk pemrosesan b.indo
 2 !pip install Sastrawi
     Collecting Sastrawi
      Downloading Sastrawi-1.0.1-py2.py3-none-any.whl (209 kB)
                                                  209.7/209.7 kB 2.0 MB/s eta 0:00:00
     Installing collected packages: Sastrawi
     Successfully installed Sastrawi-1.0.1
 1 # Instalasi paket pandas
 2 !pip install pandas
     Requirement already satisfied: pandas in /usr/local/lib/python3.10/dist-packages (1.5.3)
     Requirement already satisfied: python-dateutil>=2.8.1 in /usr/local/lib/python3.10/dist-packages (from pandas) (2.8.2)
     Requirement already satisfied: pytz>=2020.1 in /usr/local/lib/python3.10/dist-packages (from pandas) (2023.3.post1)
     Requirement already satisfied: numpy>=1.21.0 in /usr/local/lib/python3.10/dist-packages (from pandas) (1.23.5)
     Requirement already satisfied: six>=1.5 in /usr/local/lib/python3.10/dist-packages (from python-dateutil>=2.8.1->pandas) (1.16.0)
 1 # Mengimpor pustaka pandas dg alias 'pd' utk manipulasi dan analisis data.
 2 import pandas as pd
 4 # Mengimpor modul re (regular expression) untuk operasi pemrosesan string.
 5 import re
 6 import nltk
 8 # Mengimpor modul word_tokenize dari nltk untuk pemisahan kata.
 9 from nltk.tokenize import word_tokenize
10
11 # Mengimpor modul stopwords dari nltk utk mendapatkan kata-kata yang umumnya diabaikan.
12 from nltk.corpus import stopwords
14 # Mengimpor kelas StemmerFactory dari pustaka Sastrawi. Sastrawi adalah pustaka untuk pemrosesan bahasa Indonesia.
```

```
1 # Import required Python package
 3 # Install Node.js (because tweet-harvest built using Node.js)
 5 # Instal paket yg diperlukan utk manajemen sertifikat, pengunduhan, & dukungan GPG.
 6 !sudo apt-get install -y ca-certificates curl gnupg
 7 # Membuat direktori utk menyimpan kunci GPG yg digunakan oleh Node.js.
 8 !sudo mkdir -p /etc/apt/keyrings
 9 # Instal kunci GPG dari Node.js & simpan dlm bentuk yg dpt digunakan oleh apt.
10 !curl -fsSL https://deb.nodesource.com/gpgkey/nodesource-repo.gpg.key | sudo gpg --dearmor -o /etc/apt/keyrings/nodesource.gpg
11
12 # Menetapkan variabel lingkungan NODE_MAJOR ke 20 & menambahkan repository Node.js ke daftar sumber apt.
13 !NODE_MAJOR=20 && echo "deb [signed-by=/etc/apt/keyrings/nodesource.gpg] https://deb.nodesource.com/node_$NODE_MAJOR.x nodistro main
14
15 # Melakukan pembaruan lg setelah menambahkan sumber baru.
16 !sudo apt-get update
17 # Menginstal Node.js dg opsi -y utk menyetujui otomatis semua permintaan unduhan.
18 !sudo apt-get install nodejs -y
19
20 # Menampilkan versi Node.js yg telah diinstal.
21 !node -v
     Hit:1 <a href="https://cloud.r-project.org/bin/linux/ubuntu">https://cloud.r-project.org/bin/linux/ubuntu</a> jammy-cran40/ InRelease
```

```
Hit:2 <a href="http://security.ubuntu.com/ubuntu">http://security.ubuntu.com/ubuntu</a> jammy-security InRelease
Hit:3 https://developer.download.nvidia.com/compute/cuda/repos/ubuntu2204/x86_64 InRelease
Hit:4 https://deb.nodesource.com/node_20.x nodistro InRelease
Hit:5 <a href="http://archive.ubuntu.com/ubuntu">http://archive.ubuntu.com/ubuntu</a> jammy InRelease
Hit:6 <a href="http://archive.ubuntu.com/ubuntu">http://archive.ubuntu.com/ubuntu</a> jammy-updates InRelease
Hit:7 http://archive.ubuntu.com/ubuntu jammy-backports InRelease
Hit:8 <a href="https://ppa.launchpadcontent.net/c2d4u.team/c2d4u4.0+/ubuntu">https://ppa.launchpadcontent.net/c2d4u.team/c2d4u4.0+/ubuntu</a> jammy InRelease
Hit:9 <a href="https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu">https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu</a> jammy InRelease
Hit:10 <a href="https://ppa.launchpadcontent.net/graphics-drivers/ppa/ubuntu">https://ppa.launchpadcontent.net/graphics-drivers/ppa/ubuntu</a> jammy InRelease
Hit:11 <a href="https://ppa.launchpadcontent.net/ubuntugis/ppa/ubuntu">https://ppa.launchpadcontent.net/ubuntugis/ppa/ubuntu</a> jammy InRelease
Reading package lists... Done
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
ca-certificates is already the newest version (20230311ubuntu0.22.04.1).
curl is already the newest version (7.81.0-1ubuntu1.15).
gnupg is already the newest version (2.2.27-3ubuntu2.1).
0 upgraded, 0 newly installed, 0 to remove and 40 not upgraded.
gpg: cannot open '/dev/tty': No such device or address
curl: (23) Failed writing body
deb [signed-by=/etc/apt/keyrings/nodesource.gpg] https://deb.nodesource.com/node_20.x nodistro main
Hit:1 <a href="https://cloud.r-project.org/bin/linux/ubuntu">https://cloud.r-project.org/bin/linux/ubuntu</a> jammy-cran40/ InRelease
Hit:2 <a href="http://archive.ubuntu.com/ubuntu">http://archive.ubuntu.com/ubuntu</a> jammy InRelease
Hit:3 https://developer.download.nvidia.com/compute/cuda/repos/ubuntu2204/x86_64 InRelease
Hit:4 <a href="http://archive.ubuntu.com/ubuntu">http://archive.ubuntu.com/ubuntu</a> jammy-updates InRelease
Hit:5 https://deb.nodesource.com/node_20.x nodistro InRelease
Hit:6 <a href="http://archive.ubuntu.com/ubuntu">http://archive.ubuntu.com/ubuntu</a> jammy-backports InRelease
Hit:7 <a href="http://security.ubuntu.com/ubuntu">http://security.ubuntu.com/ubuntu</a> jammy-security InRelease
Hit:8 https://ppa.launchpadcontent.net/c2d4u.team/c2d4u4.0+/ubuntu jammy InRelease
Hit:9 <a href="https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu">https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu</a> jammy InRelease
Hit:10 <a href="https://ppa.launchpadcontent.net/graphics-drivers/ppa/ubuntu">https://ppa.launchpadcontent.net/graphics-drivers/ppa/ubuntu</a> jammy InRelease
Hit:11 <a href="https://ppa.launchpadcontent.net/ubuntugis/ppa/ubuntu">https://ppa.launchpadcontent.net/ubuntugis/ppa/ubuntu</a> jammy InRelease
Reading package lists... Done
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
nodejs is already the newest version (20.10.0-1nodesource1).
0 upgraded, 0 newly installed, 0 to remove and 40 not upgraded.
v20.10.0
```

## Menggunakan tweet-harvest untuk melakukan crawling data dari Twitter

- -o: Nama file output untuk menyimpan hasil crawling (diberikan nilai dari variabel filename)
- -s: Kata kunci pencarian di Twitter (diberikan nilai dari variabel search\_keyword)
- -l: Batas jumlah tweet yang akan diambil (diberikan nilai dari variabel limit)

## Cara Melihat AUTH TOKEN:

- · Buka laman tweeter akun kita.
- Klik kanan > Inspect > Application > Drop-down 'Cookies' > Cari Auth Token

```
12/30/23, 12:48 AM
                                                                   21110022 Virgie Yunita Salsabil - Evaluasi CPMK 1 - Colaboratory
      1 # Crawl Data
      3 # Nama file untuk menyimpan hasil crawling
      4 filename = '1.Crawling_Data.csv'
      6 # Kata kunci pencarian di Twitter
      7 search_keyword = 'skincare'
      9 # Batas jumlah tweet yang akan diambil
     10 limit = 200
     11
     12 !npx --yes tweet-harvest@latest -o "{filename}" -s "{search_keyword}" -l {limit}
           Welcome to the Twitter Crawler
           This script uses Chromium Browser to crawl data from Twitter with *your* Twitter auth token.
           Please enter your Twitter auth token when prompted.
           Note: Keep your access token secret! Don't share it with anyone else.
           Note: This script only runs on your local device.
           ? What's your Twitter auth token? → ₾7回8? What's your Twitter auth token? → *₺7回8? What's your Twitter auth token? → **Ტ7回8? What
           up to date, audited 4 packages in 563ms
           found 0 vulnerabilities
           Installing dependencies...
           Hit:1 <a href="https://cloud.r-project.org/bin/linux/ubuntu">https://cloud.r-project.org/bin/linux/ubuntu</a> jammy-cran40/ InRelease
           Hit:2 https://developer.download.nvidia.com/compute/cuda/repos/ubuntu2204/x86_64 InRelease
           Hit:3 https://deb.nodesource.com/node_20.x nodistro InRelease
           Hit:4 <a href="http://archive.ubuntu.com/ubuntu">http://archive.ubuntu.com/ubuntu</a> jammy InRelease
           Hit:5 <a href="http://security.ubuntu.com/ubuntu">http://security.ubuntu.com/ubuntu</a> jammy-security InRelease
           Hit:6 <a href="http://archive.ubuntu.com/ubuntu">http://archive.ubuntu.com/ubuntu</a> jammy-updates InRelease
           Hit:7 <a href="http://archive.ubuntu.com/ubuntu">http://archive.ubuntu.com/ubuntu</a> jammy-backports InRelease
           Hit:8 https://ppa.launchpadcontent.net/c2d4u.team/c2d4u4.0+/ubuntu jammy InRelease
           Hit:9 <a href="https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu">https://ppa.launchpadcontent.net/deadsnakes/ppa/ubuntu</a> jammy InRelease
           Hit:10 <a href="https://ppa.launchpadcontent.net/graphics-drivers/ppa/ubuntu">https://ppa.launchpadcontent.net/graphics-drivers/ppa/ubuntu</a> jammy InRelease
           Hit:11 <a href="https://ppa.launchpadcontent.net/ubuntugis/ppa/ubuntu">https://ppa.launchpadcontent.net/ubuntugis/ppa/ubuntu</a> jammy InRelease
           Reading package lists... Done
```

	created_at	id_str	full_text	quote_count	reply_count	retwee
0	Fri Dec 29 02:44:14 +0000 2023	1740564352913330435	Jelang akhir tahun ini aku sempet istirahatin	0	8	
1	Fri Dec 29 06:32:19 +0000 2023	1740621752894705726	hayuukk giveaway skincare rombongan akhir tahu	8	314	
2	Fri Dec 29 09:08:47 +0000 2023	1740661129968484849	Sometimes I frustrated betul bila PMS datang	0	1	
3	Sun Dec 24 11:41:55 +0000 2023	1738887726362177614	Skincare edisi holiday season! 🗳 🗘 kalo lagi li	1	11	
4	Fri Dec 22 13:29:44 +0000 2023	1738190082425950706	Giveaway Skincare Untuk 1 orang pemenang. Ca	10	184	
214	Fri Dec 29 09:04:21 +0000 2023	1740660013314765103	Ubel ada ide urebranding imej @pepengbison Gi	0	11	
215	Fri Dec 29 07:00:00 +0000 2023	1740628719285203275	Start from now! <b>2023</b> <i>YEAR END SALE</i> ★ 29-31 Des	0	0	
216	Tue Dec 26 15:14:45 +0000 2023	1739666063347073450	Butuh rekomendasi face moisturizer yang ga mas	0	17	
217	Tue Dec 26 09:38:43 +0000 2023	1739581497731137854	Dr semua bisnis kecil- kecilan yg pernah aku co	1	3	
	Eri Doc 20		🍘 : What do			
selecte	d_columns =	kolom "username" dar ['username', 'full_te selected_columns]	_			

1 # 2 se 3 su

	username	full_text		
0	Far_Rida_	Jelang akhir tahun ini aku sempet istirahatin		
1	hmtly	hayuukk giveaway skincare rombongan akhir tahu		
2	umiizani	Sometimes I frustrated betul bila PMS datang		
3	irapersa	Skincare edisi holiday season!		
4	_mutiaraaaf	☆Giveaway Skincare ☆ Untuk 1 orang pemenang. Ca		
214	ubel_bluebell	Ubel ada ide urebranding imej @pepengbison Gi		
215	Adara_ID	Start from now! 2023 YEAR END SALE 🛠 29-31 Des		
216	todayis_pat	Butuh rekomendasi face moisturizer yang ga mas		
217	amysorayaa	Dr semua bisnis kecil-kecilan yg pernah aku co		
218	msbb_id	🍘 : What do you want in 2024? 😣 : Alis teb		
219 rows × 2 columns				

<sup>5 #</sup> Menampilkan DataFrame hasil seleksi
6 display(subset\_data)

#### ✓ 2. CPMK1- Sub CPMK1.1. ( bobot : 25 )

- · Lakukan pembersihan meliputi penghapusan punctuation, angka dan karakter yang tidak penting menggunakan menggunakan regex.
- · Simpan hasilnya menjadi file csv/excel.

10 # Menampilkan DataFrame yang sudah dimodifikasi

11 subset data

```
1 # Membersihkan kolom full_text
 2 def clean_text(text):
       # Menghapus semua karakter selain huruf (a-z, A-Z) dan spasi dari teks.
       cleaned_text = re.sub(r'[^a-zA-Z\s]', '', text)
 5
       return cleaned_text
 7 # Mengaplikasikan fungsi clean_text ke kolom full_text dan menambahkan hasilnya sebagai kolom baru 'cleaned_text'
 8 subset_data['cleaned_text'] = subset_data['full_text'].apply(clean_text)
10 # Tampilkan dataset
11 subset_data
     <ipython-input-32-ba80c261b5a2>:8: SettingWithCopyWarning:
     A value is trying to be set on a copy of a slice from a DataFrame.
     Try using .loc[row_indexer,col_indexer] = value instead
     See the caveats in the documentation: <a href="https://pandas.pydata.org/pandas-docs/stable/u">https://pandas.pydata.org/pandas-docs/stable/u</a>
        subset_data['cleaned_text'] = subset_data['full_text'].apply(clean_text)
              username
                                                full_text
                                                                              cleaned text
                                                                                               \blacksquare
                            Jelang akhir tahun ini aku sempet
                                                            Jelang akhir tahun ini aku sempet
                                                                                               ıl.
              Far_Rida
       0
                                               istirahatin ...
                                                                                istirahatin ...
                                  hayuukk giveaway skincare
                                                                   hayuukk giveaway skincare
       1
                  hmtly
                                     rombongan akhir tahu...
                                                                      rombongan akhir tahu...
                             Sometimes I frustrated betul bila
                                                              Sometimes I frustrated betul bila
       2
                umiizani
                                             PMS datang ...
                                                                              PMS datang ...
                          Skincare edisi holiday season! 

                                                                Skincare edisi holiday season
       3
                irapersa
                                                kalo lagi li...
                                                                              kalo lagi libur...

☆Giveaway Skincare ☆ Untuk 1

                                                              Giveaway Skincare Untuk orang
             mutiaraaaf
                                     orang pemenang. Ca...
                                                                         pemenang Carany...
                                Ubel ada ide urebranding imej
                                                                Ubel ada ide urebranding imej
      214 ubel_bluebell
                                         @pepengbison Gi...
                                                                         pepengbison Gim...
                            Start from now! 2023 YEAR END
                                                                Start from now Desember Beli
      215
               Adara_ID
                                       SALE ★ 29-31 Des...
                                                                                  skincare ...
 1 # Membersihkan kolom username
 2 def clean_username(username):
       # Menghapus semua karakter selain huruf (a-z, A-Z) dan spasi dari username.
       cleaned_username = re.sub(r'[^a-zA-Z\s]', '', username)
 4
       return cleaned username
 7 # Mengaplikasikan fungsi clean_username ke kolom username dan menambahkan hasilnya sebagai kolom baru 'cleaned_username'
 8 subset_data['cleaned_username'] = subset_data['username'].apply(clean_username)
```

```
See the caveats in the documentation: <a href="https://pandas.pydata.org/pandas-docs/stable/u">https://pandas.pydata.org/pandas-docs/stable/u</a>
subset_data['cleaned_username'] = subset_data['username'].apply(clean_username)

1  # Membuat DataFrame baru tanpa kolom 'full_text' dan 'username'

2  CLEAN = subset_data.drop(['full_text', 'username'], axis=1)

3  # Menampilkan DataFrame baru yang telah dibuat

5  CLEAN
```

	<pre>cleaned_text</pre>	cleaned_username		
0	Jelang akhir tahun ini aku sempet istirahatin	FarRida		
1	hayuukk giveaway skincare rombongan akhir tahu	hmtly		
2	Sometimes I frustrated betul bila PMS datang	umiizani		
3	Skincare edisi holiday season kalo lagi libur	irapersa		
4	Giveaway Skincare Untuk orang pemenang Carany	mutiaraaaf		
214	Ubel ada ide urebranding imej pepengbison Gim	ubelbluebell		
215	Start from now Desember Beli skincare	AdaraID		
216	Butuh rekomendasi face moisturizer yang ga mas	todayispat		
217	Dr semua bisnis kecilkecilan yg pernah aku cob	amysorayaa		
218	What do you want in Alis tebal dan bulu m	msbbid		
219 rows × 2 columns				

<ipython-input-33-76f12a761967>:8: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.

Try using .loc[row\_indexer,col\_indexer] = value instead

1 # Menyimpan DataFrame CLEAN ke dalam file CSV dengan nama '2.Data\_Cleaned.csv' tanpa menyertakan indeks 2 CLEAN.to\_csv('2.Data\_Cleaned.csv', index=False)

### → 3. CPMK1- Sub CPMK1.2.

a. Lakukan parsing dan simpan hasilnya dalam bentuk excel/csv (bobot:10)

```
1 # Mengimpor pustaka nltk
2 import nltk
3
4 # Mengunduh "punkt" dari nltk
5 nltk.download('punkt')

[nltk_data] Downloading package punkt to /root/nltk_data...
[nltk_data] Unzipping tokenizers/punkt.zip.
True

1 # Membaca file CSV dengan nama '2.Data_Cleaned.csv' ke dalam DataFrame 'Data_3A'
2 Data_3A = pd.read_csv('2.Data_Cleaned.csv')
3
4 # Menampilkan DataFrame 'Data_3A'
5 Data_3A
```

```
1 # Menggunakan metode word_tokenize dari nltk untuk memecah teks pada kolom 'cleaned_text' menjadi token (kata-kata)
2 Data_3A['parse_text'] = Data_3A['cleaned_text'].apply(word_tokenize)
3
4 # Menggunakan metode word_tokenize dari nltk untuk memecah teks pada kolom 'cleaned_username' menjadi token (kata-kata)
5 Data_3A['parse_name'] = Data_3A['cleaned_username'].apply(word_tokenize)
6
7 # Menampilkan DataFrame 'Data_3A' yang telah dimodifikasi dengan tambahan kolom 'parse_text' dan 'parse_name'
8 Data_3A
```

	<pre>cleaned_text</pre>	cleaned_username	parse_text	parse_name	#	
0	Jelang akhir tahun ini aku sempet istirahatin	FarRida	[Jelang, akhir, tahun, ini, aku, sempet, istir	[FarRida]	th	
1	hayuukk giveaway skincare rombongan akhir tahu	hmtly	[hayuukk, giveaway, skincare, rombongan, akhir	[hmtly]		
2	Sometimes I frustrated betul bila PMS datang	umiizani	[Sometimes, I, frustrated, betul, bila, PMS, d	[umiizani]		
3	Skincare edisi holiday season kalo lagi libur	irapersa	[Skincare, edisi, holiday, season, kalo, lagi,	[irapersa]		
4	Giveaway Skincare Untuk orang pemenang Carany	mutiaraaaf	[Giveaway, Skincare, Untuk, orang, pemenang, C	[mutiaraaaf]		
214	Ubel ada ide urebranding imej pepengbison Gim	ubelbluebell	[Ubel, ada, ide, urebranding, imej, pepengbiso	[ubelbluebell]		
215	Start from now Desember Beli skincare	AdaralD	[Start, from, now, Desember, Beli, skincare, h	[AdaraID]		
216	Butuh rekomendasi face moisturizer yang ga mas	todayispat	[Butuh, rekomendasi, face, moisturizer, yang,	[todayispat]		
217	Dr semua bisnis kecilkecilan yg pernah aku cob	amysorayaa	[Dr, semua, bisnis, kecilkecilan, yg, pernah,	[amysorayaa]		
218	What do you want in Alis tebal dan bulu m	msbbid	[What, do, you, want, in, Alis, tebal, dan, bu	[msbbid]		
219 rows × 4 columns						

```
1 # Data parsing
2 data_parsing = Data_3A.drop(['cleaned_text', 'cleaned_username'], axis = 1)
3
4 # Tampilkan data
5 data_parsing
```

```
parse text parse name
  0
              [Jelang, akhir, tahun, ini, aku, sempet, istir...
                                                                [FarRida]
  1
        [hayuukk, giveaway, skincare, rombongan, akhir...
                                                                   [hmtly]
  2
            [Sometimes, I. frustrated, betul, bila, PMS, d...
                                                                [umiizani]
  3
             [Skincare, edisi, holiday, season, kalo, lagi,...
                                                                [irapersa]
  4
       [Giveaway, Skincare, Untuk, orang, pemenang, C...
                                                              [mutiaraaaf]
 ...
214
          [Ubel, ada, ide, urebranding, imej, pepengbiso... [ubelbluebell]
           [Start, from, now, Desember, Beli, skincare, h...
                                                                [AdaraID]
215
                                                              [todayispat]
216
          [Butuh, rekomendasi, face, moisturizer, yang, ...
217
            [Dr, semua, bisnis, kecilkecilan, yg, pernah, ... [amysorayaa]
218
             [What, do, you, want, in, Alis, tebal, dan, bu...
                                                                 [msbbid]
219 rows × 2 columns
```

```
1 # Menyimpan DataFrame 'data_parsing' ke file CSV dengan nama '3A.Data_Parsing.csv' tanpa menyertakan indeks 2 data_parsing.to_csv('3A.Data_Parsing.csv', index=False)
```

- b. Carilah kata-kata slangword yang ada dalam dataset Anda, dengan cara mencocokan dengan kamus KBBI (terlampir).
  - Simpan hasilnya dalam bentuk csv/excel.
  - Tampilkan 100 kata slang yang Anda dapatkan dan tampilkan dalam bentuk Gunakan (bobot:25)

```
1 # Membaca file CSV yang berisi kata-kata slang
2 slang = pd.read_csv('stopwords.csv')
3
4 # Tampilkan data
5 slang
```

```
Slangwords
                       翩
  n
             Adam
  1
               Aga
  2
           Agustus
  3
             Ahad
  4
            Ajisaka
47295
              zulu
47296
            zurafah
47297
            zuriah
47298
             zuriat
47299
               7US
```

```
1 # Mengambil daftar kata-kata slang dari kolom 'Slangwords' dalam DataFrame 'slang' dan mengonversikannya menjadi list
 2 slang_words = slang['Slangwords'].tolist()
4 # Fungsi untuk mencari kata-kata slang dalam teks
 5 def find_slang(text):
      # Mengambil token (kata-kata) dari teks
 6
      words = text
 8
9
      # Mencari kata-kata slang yang ada dalam teks
10
      found_slang = [word for word in words if word in slang_words]
11
12
      # Menggabungkan kata-kata slang yang ditemukan menjadi satu string, dipisahkan oleh koma
13
      return ', '.ioin(found slang)
14
15 # Menerapkan fungsi find_slang ke kolom 'parse_text' dalam DataFrame 'data_parsing' dan menambahkan hasilnya sebagai kolom baru 'fou
16 data_parsing['found_slang_in_text'] = data_parsing['parse_text'].apply(find_slang)
17
18 # Menampilkan DataFrame 'data_parsing' yang telah dimodifikasi dengan tambahan kolom 'found_slang_in_text'
19 data parsing
```

```
扁
                                              parse text
                                                              parse name
                                                                                                         found slang in text
  0
              [Jelang, akhir, tahun, ini, aku, sempet, istir...
                                                                 [FarRida]
                                                                                     akhir, tahun, ini, aku, kulit, wajah, aku, dar...
                                                                                                                                     ıl.
                                                                    [hmtly]
  1
        [hayuukk, giveaway, skincare, rombongan, akhir...
                                                                             rombongan, akhir, tahun, mau, nomor, berapa, p...
  2
            [Sometimes, I, frustrated, betul, bila, PMS, d...
                                                                 [umiizani]
                                                                                    betul, bila, datang, tak, pernah, bagi, nak, r...
  3
             [Skincare, edisi, holiday, season, kalo, lagi,...
                                                                 [irapersa]
                                                                                  edisi, kalo, lagi, liburan, biasanya, bawa, mu...
  4
       [Giveaway, Skincare, Untuk, orang, pemenang, C...
                                                              [mutiaraaaf] orang, pemenang, gampang, aku, domisili, kamu,...
214
          [Ubel, ada, ide, urebranding, imej, pepengbiso... [ubelbluebell]
                                                                                  ada, ide, kalo, personal, jadi, yang, kaya, ba...
215
           [Start, from, now, Desember, Beli, skincare, h...
                                                                 [AdaraID]
                                                                                Desember, hemat, hingga, start, aja, juga, bak...
216
          [Butuh, rekomendasi, face, moisturizer, yang, ...
                                                               [todayispat]
                                                                               rekomendasi, yang, masuk, boikot, selain, dan,...
217
            [Dr, semua, bisnis, kecilkecilan, yg, pernah, ... [amysorayaa]
                                                                               semua, bisnis, pernah, aku, coba, mulai, panas...
218
             [What, do, you, want, in, Alis, tebal, dan, bu...
                                                                  [msbbid]
                                                                                       do, tebal, dan, bulu, mata, panjang, lentik
219 rows × 3 columns
```

```
1 # Mengambil kata-kata slang yang telah ditemukan
2 found_slang_list = data_parsing['found_slang_in_text'].str.split(', ').explode().tolist()
3
4 # Menyimpan seluruh slang ke dalam 'all slang'
5 all_slang = found_slang_list

1 # Mengambil 100 kata terakhir
2 slang_100 = found_slang_list[-100:]
3
4 # Menampilkan 100 kata slang terakhir
5 slang_100
['dong',
```

```
'biar',
'kulit',
'wajah',
'sehat',
'jadi',
```

```
'nih',
      'muka'
      'lagi',
      'sering',
      'aku',
      'banyak',
      'yang',
      'ini',
      'ya',
      'definisi',
      'campuran',
      'manis',
      'dan',
'juga',
      'mendeskripsikan',
      'wangi',
'wanita',
      'dewasa',
      'seserahan',
      'yang',
'contoh',
      '',
'ada',
      'ide',
'kalo'
      'personal',
      'jadi',
      'yang',
      'kaya'
      'banget',
      'dengan',
      'penghasilan',
      'per',
'hari'
      'banyak',
      'yang',
      'suka',
      'Desember',
      'hemat',
'hingga',
      'start',
      'aja',
'juga'
      'bakalan',
      'hadiah',
      'produk',
      'favorit',
      'kamu',
      'yang',
      'rekomendasi',
      'yang',
'masuk',
1 # Membuat DataFrame dari list kata-kata slang
2 all_slang_df = pd.DataFrame({'all_slang': all_slang})
3 all_slang_df
```

```
\blacksquare
        all_slang
  0
              akhir
                         th
  1
             tahun
  2
                ini
  3
               aku
  4
               kulit
  ...
2572
               dan
2573
              bulu
2574
             mata
2575
           panjang
2576
             lentik
2577 rows × 1 columns
```

```
1 # Simpan DataFrame ke dalam file CSV
2 all_slang_df.to_csv('3B.Data_Slang.csv', index=False)
```

# c. Lakukan tokenizing berdasarkan hasil 3b

- · simpan hasilnya dalam bentuk csv/excel
- tampilkan 100 token pertama. (bobot:10)

```
1 # Import library yang diperlukan
2 from nltk.tokenize import word_tokenize
3
4 # Tokenizing kolom 'all_slang'
5 all_slang_df['tokens'] = all_slang_df['all_slang'].apply(word_tokenize)
6
7 # Tampilkan DataFrame setelah tokenizing
8 display(all_slang_df)
```

	all_slang	tokens			
0	akhir	[akhir]	11.		
1	tahun	[tahun]			
2	ini	[ini]			
3	aku	[aku]			
4	kulit	[kulit]			
2572	dan	[dan]			
2573	bulu	[bulu]			
2574	mata	[mata]			
2575	panjang	[panjang]			
2576	lentik	[lentik]			
2577 rows × 2 columns					

```
1 # Menampilkan 100 token pertama
2 display(all_slang_df['tokens'].head(100))
```

```
[akhir]
a
1
        [tahun]
2
           [ini]
3
           [aku]
4
        [kulit]
95
         [lalu]
96
          [dan]
97
      [terlalu]
98
       [mempan]
99
           [aku]
Name: tokens, Length: 100, dtype: object
```

```
1 # Simpan hasil tokenizing ke dalam file CSV
2 all_slang_df.to_csv('3C.Data_Slang_Tokenized.csv', index=False)
```

# ✓ d. Lakukan stopword removing berdasarkan hasil 3c

• simpan hasilnya dalam bentuk csv/excel. (bobot:10)

```
1 # Mengimpor modul nltk dan mengunduh data stopwords
2 import nltk
3 nltk.download('stopwords')

    [nltk_data] Downloading package stopwords to /root/nltk_data...
    [nltk_data] Unzipping corpora/stopwords.zip.
    True

1 # Daftar kata-kata yang telah Anda berikan
2 daftar_kata = all_slang
3
4 # Menggunakan NLTK untuk mendapatkan daftar stopword dalam bahasa Indonesia
5 stopwords_list = set(stopwords.words('indonesian'))
6
7 # Menghapus stopword dari daftar kata-kata
8 filter_words = [word for word in daftar_kata if word not in stopwords_list]
9
10 # Menampilkan hasil setelah penghapusan stopword
11 filter_words
```

```
'pakai',
'rehat',
'rombongan',
'nomor',
'pemenang',
'ya',
'nak',
'jerawat',
'bawa',
'kawan',
'kawan',
'nak',
'edisi',
'kalo',
'liburan',
'bawa',
'habis',
'orang',
'pemenang',
'gampang',
'domisili',
'tanggal',
'Januari',
'tanggung',
'berkembang',
'jualan',
'jujur',
'deh',
'rutin',
'maksimal',
'cerita',
'mempan',
'tau',
'ampuh',
'pas',
'iklan',
'si',
'pura',
'telpon',
'kabur',
'pas',
'selesai',
'ba',
'produk',
'banget',
'beli',
'aja',
'konsultasi',
'dokter',
'gratis',
'jam',
'salah',
'premium'
'formulasi',
'dokter',
'super',
'plug',
```

```
1 # Membuat DataFrame dari hasil penghapusan stopword
2 result_stopword = pd.DataFrame({'hasil_stopwords': filter_words})
4 # Tampilkan
5 result_stopword
```

	hasil_stopwords	
0	kulit	ıl.
1	wajah	
2	bagus	
3	kulit	
4	wajah	
1303	do	
1304	tebal	
1305	bulu	
1306	mata	
1307	lentik	
1308 r	ows × 1 columns	

```
1 # Menyimpan hasilnya ke dalam file CSV
2 result_stopword.to_csv('3D.Hasil_Stopwords.csv', index=False)
```

• e. Lakukan stemming berdasarkan hasil 3d dan tampilkan 100 stem pertama. (bobot:10)

```
1 from Sastrawi.Stemmer.StemmerFactory import StemmerFactory
2
3 # Inisialisasi stemmer
4 stemmer_factory = StemmerFactory()
5 stemmer = stemmer_factory.create_stemmer()
6
7 # Melakukan stemming pada hasil penghapusan stopword
8 result_stopword['stem'] = result_stopword['hasil_stopwords'].apply(stemmer.stem)
9
10 # Menampilkan 100 stem pertama
11 display(result_stopword['stem'].head(100).to_frame(name='100_stem_pertama'))
```

	100_stem_pertama	
0	kulit	ıl.
1	wajah	
2	bagus	
3	kulit	
4	wajah	
95	person	
96	malas	
07		